V-QMin: Crawler Enfocado Multimodal mediante Señales Visuales CLIP y Calidad Textual

Jose Emanuel Rodriguez
Licenciatura en Sistemas de Información
Universidad Nacional de Luján
Luján, Buenos Aires, Argentina
joseemaro@hotmail.com

***Resumen*—Los crawlers enfocados tradicionales priorizan páginas web utilizando unicamente señales textuales, sin tener en cuenta el contenido visual que suele acompañar a documentos de alta calidad en dominios como la educación STEM. Este trabajo presenta V-QMin, un crawler enfocado multimodal que combina un estimador de calidad textual (Q_{text}), inspirado en el trabajo de priorización neuronal de Pezzuti et al., con un estimador de relevancia visual (Rel_{visual}) basado en embeddings CLIP para guiar la exploración del grafo web. La función de scoring híbrida $S(u) = \alpha \cdot Q_{text}(p) + (1 - \alpha) \cdot Rel_{visual}(u, q)$ integra ambas señales mediante un parámetro α que actua de balanceador, y la política de actualización QMin (conservadora) evita la sobrevaloración de nodos redescubiertos. Se evalúa V-QMin sobre un grafo sintético de 50,000 nodos construido a partir de 10,000 registros reales del dataset VisualWebInstruct-verified, comparándolo contra baselines BFS y Text-Only mediante Harvest Rate (HR@K), nDCG@K y test de Wilcoxon. Los resultados muestran que V-QMin con $\alpha = 0{,}2$ alcanza HR@500 = 0.992, superando a Text-Only (0.660, +50.3 %) y a BFS (0.227, +337 %), con diferencias estadísticamente significativas ($p < 0{,}001$). Se realizan tres experimentos complementarios: (i) una comparacion del encoder visual ViT-B/16 contra ViT-L/14, que confirma la suficiencia del modelo base; (ii) un análisis de robustez variando la proporción de distractores difíciles (20 %–80 %), donde la ventaja de V-QMin crece de +36 % a +71 %; y (iii) una validación con 50 queries que fortalece la significancia estadística ($p < 10^{-9}$). En conjunto, los resultados confirman que las señales visuales aportan valor sustancial en la priorización de páginas en dominios con contenido visual rico.**

***Términos de Índice*—crawler enfocado, recuperación de información multimodal, CLIP, embeddings visuales, calidad textual, grafo web, harvest rate, educación STEM.**

I. Introducción

I-A. Motivación y Contexto

La World Wide Web contiene una cantidad masiva de información distribuida en miles de millones de páginas interconectadas. En dominios especializados, como la educación STEM (ciencias, tecnología, ingeniería y matemáticas), la investigación científica o la documentación técnica, las páginas de mayor valor suelen combinar contenido textual de calidad con material visual complementario: diagramas, gráficos, fórmulas renderizadas y fotografías explicativas. Sin embargo, los crawlers enfocados convencionales [1], [2] priorizan la exploración utilizando exclusivamente señales textuales, ignorando la riqueza informativa del contenido visual.

Esta limitación resulta en dos problemas concretos. Primero, el crawler no puede distinguir entre una página textualmente relevante pero visualmente pobre (por ejemplo, un foro con respuestas superficiales) y una página con contenido visual-educativo de alta calidad (por ejemplo, un problema de geometría con su diagrama correspondiente). Segundo, al depender únicamente de condiciones textuales como la longitud de la respuesta o la presencia de ciertos términos, el crawler es vulnerable a "distractores duros": páginas con indicadores de calidad textual altos pero sin contenido visual relevante para la tarea.

Los avances recientes en dos áreas complementarias ofrecen oportunidades para superar estas limitaciones. Por un lado, la priorización neuronal para crawling web [4] ha demostrado que modelos de lenguaje pueden estimar la calidad del contenido textual para ordenar la frontera de rastreo de forma más efectiva que las tecnicas clásicas. Por otro lado, los modelos de representación multimodal como CLIP (*Contrastive Language-Image Pretraining*) [5] permiten codificar imágenes y texto en un espacio compartido de 512 dimensiones, lo que permite calcular qué tan relacionados están una consulta textual y el contenido visual de una página web, sin necesidad de entrenar el modelo para cada dominio.

I-B. Planteamiento del Problema

Dado un grafo web $G = (V, E)$ donde V es el conjunto de páginas y E el conjunto de hipervínculos, un conjunto de nodos semilla $S \subseteq V$, y una consulta temática q, el problema del *focused crawling* consiste en visitar un subconjunto $V_K \subseteq V$ de tamaño K que maximice la proporción de páginas relevantes (*targets*) descubiertas. Formalmente, se busca maximizar el *Harvest Rate*:

$$HR@K = \frac{|\{v \in V_K : v \in T\}|}{K} \tag{1}$$

donde $T \subseteq V$ es el conjunto de páginas relevantes. Este trabajo expande este problema incorporando señales visuales: cada página v posee no solo contenido textual p_v sino también contenido visual i_v (imágenes), y el crawler debe aprovechar ambas condiciones para mejorar $HR@K$.

La formula anterior asume un presupuesto de crawling finito K, lo cual refleja las restricciones prácticas de ancho de banda, almacenamiento y tiempo de procesamiento que enfrentan los crawlers reales [11]. Najork y Wiener [3] demostraron que incluso BFS (Breadth-First Search) produce páginas de

mayor calidad que el promedio web, estableciendo un baseline no trivial. Sin embargo, en dominios especializados como STEM, donde las páginas relevantes constituyen una parte muy pequeña del total, las estrategias no guiadas resultan ineficientes, motivando el desarrollo de crawlers enfocados más sofisticados.

I-C. Preguntas de Investigación

Este trabajo se estructura en torno a las siguientes preguntas, que profundizan las formuladas en la propuesta original del proyecto:

1. **PI-1:** ¿La integración de señales visuales CLIP mejora significativamente el Harvest Rate de un crawler enfocado respecto a enfoques puramente textuales?
2. **PI-2:** ¿Cuál es el balance óptimo entre calidad textual y relevancia visual (parámetro α), y cómo se comporta la función de scoring en los extremos?
3. **PI-3:** ¿La señal visual permite discriminar entre contenido textualmente similar pero visualmente diferente (hard distractors)?
4. **PI-4:** ¿Los resultados son robustos a través de diferentes consultas temáticas STEM, o dependen fuertemente del tipo de contenido visual?

I-D. Contribuciones

Las contribuciones principales son:

1. **V-QMin**: Un crawler enfocado multimodal que integra calidad textual (Q_{text}) y relevancia visual CLIP (Rel_{visual}) en una función de scoring híbrida parametrizada por α.
2. **Política QMin**: Una estrategia conservadora de actualización de prioridades que conserva el score mínimo al redescubrir un nodo en la frontera, de forma de evitar que si un nodo promete mucho desde un unico vecino favorable, se sobre-priorice.
3. **Evaluación a escala**: Un protocolo experimental sobre un grafo sintético de 50,000 nodos con 10,000 targets reales del dataset VisualWebInstruct-verified [6], con distractores ajustados a dos niveles de dificultad.
4. **Análisis de sensibilidad**: Un barrido completo de α que identifica la zona óptima $\alpha = 0{,}1$–$0{,}3$ y fundamenta la recomendación de $\alpha = 0{,}2$.

El resto del documento se organiza como sigue: la Sección II revisa los trabajos previos. La Sección III detalla la arquitectura de V-QMin. La Sección IV describe el protocolo experimental. La Sección V documenta los desafíos encontrados y las decisiones de diseño. La Sección VI presenta y discute los resultados. Finalmente, la Sección VIII resume las conclusiones y propone líneas futuras.

II. Trabajos Relacionados

II-A. Crawlers Enfocados

El concepto de focused crawling fue introducido por Chakrabarti et al. [1], quienes propusieron utilizar un clasificador para estimar la relevancia de páginas no visitadas y priorizar la exploración en consecuencia. La idea central es que la estructura de enlaces de la web exhibe localidad temática: páginas relevantes tienden a enlazar a otras páginas relevantes.

Najork y Wiener [3] realizaron una contribución fundamental al demostrar empíricamente que BFS produce páginas de calidad superior al promedio web. Este resultado, aparentemente contraintuitivo, se explica por la correlación entre el in-degree de una página y su calidad: las páginas ampliamente enlazadas tienden a ser más informativas, y BFS las descubre tempranamente. Sin embargo, esta propiedad se debilita en dominios especializados donde las páginas relevantes no necesariamente tienen alto in-degree global.

Menczer et al. [2] introdujeron crawlers temáticos basados en modelos de lenguaje, evaluando diversas heurísticas de priorización. Diligenti et al. [8] propusieron el uso de *context graphs* para estimar la distancia a páginas relevantes, permitiendo al crawler "saltar" sobre regiones irrelevantes. Batsakis et al. [7] realizaron un estudio comparativo exhaustivo de estrategias de focused crawling, reportando harvest rates entre 0.3 y 0.8 según el dominio y la estrategia empleada. Este rango fundamenta el diseño de nuestro grafo experimental (Sección IV-B).

Trabajos más recientes han incorporado técnicas de aprendizaje profundo. Liu et al. [9] aplicaron redes neuronales recurrentes para predecir la relevancia de URLs no visitadas. Zhang et al. [10] exploraron el uso de aprendizaje por refuerzo para adaptar dinámicamente la estrategia de exploración. Sin embargo, ninguno de estos enfoques incorpora señales visuales del contenido de las páginas.

II-B. Priorización Neuronal para Web Crawling

Pezzuti et al. [4] propusieron recientemente un enfoque de priorización neuronal donde modelos de lenguaje estiman la calidad del texto para ordenar la frontera de rastreo. Su trabajo demuestra que las señales de calidad textual (longitud del contenido, estructura del documento, riqueza léxica) pueden ser estimadas eficientemente y utilizadas para mejorar el harvest rate respecto a heurísticas manuales. El componente Q_{text} de V-QMin se basa directamente en este enfoque, adoptando la idea de que la calidad del contenido textual de una página puede servir como filtro de su valor informativo.

Sin embargo, Pezzuti et al. se limitan a señales textuales. V-QMin extiende su enfoque al combinar la estimación de calidad textual con señales visuales, bajo la hipótesis de que en dominios STEM la modalidad visual aporta información adicional que el texto no puede aportar.

II-C. Recuperación de Información Multimodal

La integración de múltiples modalidades en sistemas de recuperación ha sido explorada en diversos contextos. Datta et al. [13] realizaron una revisión amplia de técnicas de recuperación de imágenes basadas en contenido (CBIR). Antol et al. [12] introdujeron VQA (*Visual Question Answering*), demostrando que la combinación de comprensión visual y textual es necesaria para responder preguntas sobre imágenes.

En el contexto educativo STEM, los datasets multimodales han demostrado que las imágenes son un componente esencial

del contenido. ScienceQA [14] contiene 21,208 preguntas científicas multimodales, mientras que MathVista [15] se enfoca en razonamiento matemático visual. Estos datasets evidencian que la comprensión visual es indispensable para tareas STEM, motivando la incorporación de señales visuales en la recuperación de este tipo de contenido.

Sin embargo, la aplicación de señales multimodales específicamente en el contexto de crawling web, donde las decisiones de priorización deben tomarse con información parcial y en tiempo real, permanece aun como área inexplorada. A diferencia de los sistemas de recuperación sobre colecciones estáticas, un crawler debe decidir *antes* de visitar una página si merece la pena descargarla.

II-D. Modelos de Visión-Lenguaje: CLIP

CLIP (*Contrastive Language-Image Pretraining*) [5] representó un avance significativo en la representación multimodal. Entrenado sobre 400 millones de pares imagen-texto recolectados de internet, CLIP aprende a maximizar la similitud coseno entre embeddings de imágenes y sus descripciones textuales correspondientes, mientras minimiza la similitud con pares no correspondientes.

La arquitectura de CLIP consiste en dos encoders independientes: un encoder visual (en nuestro caso, ViT-B/16 [16]) y un encoder textual basado en Transformer. Ambos producen embeddings de 512 dimensiones en un espacio compartido, donde la similitud coseno refleja qué tan relacionados están semánticamente una imagen y un texto. Esta propiedad de *zero-shot transfer* permite utilizar CLIP para tareas nuevas sin entrenamiento adicional, lo cual es particularmente valioso para un crawler que debe operar sobre dominios diversos sin fine-tuning previo.

Trabajos posteriores han aplicado CLIP en diversas tareas de recuperación: Conde y Turgutlu [20] en clasificación de arte, Luo et al. [21] en búsqueda de video, y Zhou et al. [22] en clasificación zero-shot mediante prompt engineering. Sin embargo, la aplicación de CLIP como señal de guía para la exploración de grafos web no ha sido investigada.

II-E. Calidad de Contenido Web

La estimación automática de calidad de contenido web es un problema complementario al de relevancia. Bendersky et al. [18] propusieron features basados en la estructura del documento, riqueza léxica y diversidad de vocabulario para re-rankear resultados de búsqueda. Ntoulas et al. [19] abordaron la detección de spam web, un problema análogo al de distinguir contenido de baja calidad.

En nuestro trabajo, Q_{text} cumple un rol similar al de estos estimadores de calidad, operando como un filtro rápido que descarta contenido de baja calidad antes de aplicar la señal visual, que es más costosa computacionalmente.

II-F. Posicionamiento de V-QMin

V-QMin se diferencia de los trabajos previos en cuatro aspectos fundamentales: (1) opera en el contexto dinámico de exploración de grafos, no sobre colecciones estáticas; (2) combina *calidad* textual (query-agnóstica, inspirada en Pezzuti et al. [4]) con *relevancia* visual (query-específica, basada en CLIP), aprovechando que ambas señales se complementan; (3) la política QMin añade robustez ante la exploración de múltiples caminos, un problema específico del crawling que no aparece en sistemas de recuperación estáticos; y (4) evalúa sobre un grafo sintético de escala realista (50K nodos) con ground truth completo, permitiendo un análisis exhaustivo de sensibilidad del parámetro α.

III. Metodología

III-A. Arquitectura General

V-QMin opera como un crawler enfocado con cola de prioridad (max-heap), extendiendo la arquitectura clásica de best-first search [1] con dos componentes de scoring que se combinan en una función híbrida. El crawler mantiene tres estructuras de datos principales:

- **Visitados** ($\mathcal{V}$): conjunto de nodos ya procesados.
- **Frontera** ($\mathcal{F}$): cola de prioridad (max-heap) con nodos descubiertos pero no visitados, ordenados por score.
- **Scores** ($\mathcal{S}$): mapeo de cada nodo en la frontera a su score actual.

El flujo de operación es: (1) inicializar la frontera con nodos semilla; (2) extraer el nodo de mayor score; (3) marcarlo como visitado; (4) expandir sus vecinos, computando scores y actualizando la frontera; (5) repetir hasta agotar el presupuesto K. La complejidad temporal es $O(K \cdot \log|\mathcal{F}|)$ para las operaciones de heap, más el costo de computar embeddings CLIP para cada nodo expandido.

III-B. Estimador de Calidad Textual: Q_{text}

El estimador $Q_{text}(p) \in [0,1]$ evalúa la calidad del contenido textual de una página p mediante heurísticas inspiradas en el trabajo de Pezzuti et al. [4] sobre priorización neuronal. Mientras que Pezzuti et al. utilizan modelos de lenguaje completos para la estimación, V-QMin emplea un estimador simplificado basado en features del documento que captura las señales de calidad más informativas:

$$Q_{text}(p) = \text{clip}\left(b + \sum_i w_i \cdot f_i(p) + \epsilon,\ 0{,}1,\ 0{,}95\right) \quad (2)$$

donde $b = 0{,}5$ es un score base, $f_i(p)$ son features del documento, w_i son pesos asociados, y $\epsilon \sim \mathcal{N}(0, 0{,}05)$ agrega ruido para simular la imprecisión que tendría un estimador de calidad real. La función $\text{clip}(\cdot, 0{,}1, 0{,}95)$ acota el resultado al rango $[0{,}1, 0{,}95]$, evitando scores extremos que podrían dominar la combinación con Rel_{visual}.

Los features y pesos utilizados se detallan en la Tabla I.

Estos features capturan indicadores de calidad documentados en la literatura [18], [19]: respuestas largas y bien estructuradas tienden a ser más informativas, mientras que respuestas breves sugieren contenido superficial. La presencia de URLs en el contenido indica referencias externas, asociada a contenido más riguroso.

Cuadro I: Features y Pesos del Estimador Q_{text}

Feature $f_i(p)$	**Condición**	**Peso** w_i
Longitud respuesta	> 1000 chars	$+0{,}20$
Longitud respuesta	> 500 chars	$+0{,}10$
Longitud respuesta	< 100 chars	$-0{,}10$
Longitud pregunta	> 200 chars	$+0{,}10$
Longitud pregunta	< 50 chars	$-0{,}05$
Presencia de URL	> 30 chars	$+0{,}05$

Una propiedad fundamental de Q_{text} es que es **independiente de la consulta** (q): mide la calidad intrínseca de la página, no su relevancia para un tema específico. Como señala la propuesta original del proyecto, esta propiedad es compartida con el estimador de Pezzuti et al. [4], donde la calidad textual se evalúa de forma genérica. Esta independencia tiene implicaciones directas para la interpretación del parámetro α (ver Sección V-D).

III-C. Estimador de Relevancia Visual: Rel_{visual}

El estimador $Rel_{visual}(u, q) \in [-1, 1]$ mide la similitud semántica entre el contenido visual de un nodo u y la consulta temática q:

$$Rel_{visual}(u, q) = \cos\left(\phi_{img}(i_u),\ \phi_{txt}(q)\right) \tag{3}$$

donde ϕ_{img} y ϕ_{txt} son los codificadores de imagen y texto de CLIP (ViT-B/16 con pesos preentrenados de OpenAI), implementados mediante la librería `open-clip-torch` [17]. Ambos embeddings (512 dimensiones) se normalizan a L2 unitario, por lo que la similitud coseno se reduce al producto punto.

A diferencia de Q_{text}, Rel_{visual} es **específica de la consulta**: adapta la priorización al contenido buscado. Una imagen de un circuito eléctrico tendrá alta Rel_{visual} para la consulta "electrical circuit analysis" pero baja para "organic chemistry reactions". Esta asimetría entre ambos componentes (query-agnóstico vs. query-específico) es central para entender el comportamiento del parámetro α y constituye una diferencia clave respecto al enfoque puramente textual de Pezzuti et al.

La elección de ViT-B/16 se fundamenta en su balance entre rendimiento y eficiencia computacional. Modelos más grandes como ViT-L/14 ofrecen mayor precisión pero duplican el tiempo de inferencia. En nuestro hardware (RTX 5060 Ti, 8 GB VRAM), ViT-B/16 alcanza un throughput de 97 imágenes/segundo, suficiente para procesar 10,000 imágenes en aproximadamente 103 segundos.

III-D. Función de Scoring Híbrida

La prioridad de cada nodo se determina por la combinación convexa:

$$S(u) = \alpha \cdot Q_{text}(p_u) + (1 - \alpha) \cdot \widetilde{Rel}_{visual}(u, q) \tag{4}$$

donde $\widetilde{Rel}_{visual} = (Rel_{visual} + 1)/2$ normaliza la relevancia visual al rango $[0, 1]$, y $\alpha \in [0, 1]$ controla el balance entre ambas señales. La normalización es necesaria porque $Rel_{visual} \in [-1, 1]$ mientras que $Q_{text} \in [0, 1]$; sin ella, la combinación lineal no sería una verdadera combinación convexa y la contribución de cada componente no sería proporcional a su peso α.

Los casos extremos del parámetro revelan la estructura del modelo: $\alpha = 1$ reduce V-QMin a un crawler puramente textual equivalente al baseline Text-Only, reproduciendo el enfoque de Pezzuti et al. [4] sin señal visual; $\alpha = 0$ produce priorización exclusivamente visual, ignorando la calidad textual de las páginas.

III-E. Política QMin

Al expandir un nodo, sus vecinos pueden ya existir en la frontera con un score previo asignado por un predecesor diferente. V-QMin implementa una política de actualización conservadora:

$$\mathcal{S}[v] \leftarrow \text{mín}\left(\mathcal{S}[v],\ S_{nuevo}(v)\right) \tag{5}$$

Esta política evita que un nodo sea artificialmente promovido por ser accesible desde múltiples nodos de alto score. Si un nodo tiene un score genuinamente alto, al menos uno de sus predecesores le asignará ese score. Si solo es accesible por un único camino favorable (potencialmente ruidoso), el score mínimo actúa como regularizador.

Una política "optimista" que conserva el máximo tendería a promover nodos situados en la intersección de clusters temáticos, que pueden ser conectores sin contenido relevante propio. La política pesimista favorece nodos consistentemente bien evaluados. El nombre "QMin" hace referencia explícita a esta elección: Quality-Minimum, indicando que el score de un nodo en la frontera refleja la evaluación *mínima* recibida.

III-F. Algoritmo

El Algoritmo 1 describe el procedimiento completo de V-QMin.

La implementación utiliza *lazy deletion*: cuando un nodo es re-insertado en el heap con un score menor (líneas 15–16), el registro anterior permanece en el heap pero es ignorado al ser extraído si ya fue visitado (líneas 8–9). Esto evita la costosa operación de decrease-key, reduciendo la complejidad práctica.

III-G. Detalles de Implementación

La implementación se realizó en Python 3.12 con las siguientes dependencias principales: PyTorch 2.10.0+cu128 para aceleración GPU, `open-clip-torch` 3.2.0 para los embeddings CLIP, NumPy para operaciones vectoriales, y SciPy para el test de Wilcoxon. Se utilizó `open-clip-torch` en lugar de la librería oficial `openai/CLIP` (descontinuada) por su mantenimiento activo y compatibilidad con versiones recientes de PyTorch [17].

Los embeddings CLIP se generan en GPU con precisión float16 y se normalizan a L2 unitario. Para las 10 queries textuales, los embeddings se precomputan una sola vez y se reutilizan durante todo el crawling. El procesamiento por lotes

Algorithm 1 V-QMin: Crawler Enfocado Multimodal

Require: Grafo $G = (V, E)$, semillas S, query q, α, K
Ensure: Lista ordenada de nodos visitados $\mathcal{V}$

```
V ← ∅, F ← MaxHeap vacío
q_emb ← φ_txt(q) {Embedding CLIP de la query}
for cada s ∈ S do
    F.push(s, S(s))
end for
while |V| < K and F ≠ ∅ do
    u ← F.pop() {Nodo de mayor prioridad}
    if u ∈ V then
        continue {Lazy deletion}
    end if
    V.append(u)
    for cada v ∈ vecinos(u), v ∉ V do
        s_new ← α · Q_text(v) + (1 − α) · Rel̃_visual(v, q_emb)
        if v ∈ F then
            if s_new < S[v] then
                {Política QMin}
                S[v] ← s_new
                F.push(v, s_new)
            end if
        else
            S[v] ← s_new
            F.push(v, s_new)
        end if
    end for
end while
return V
```

(batch size = 128) permite alcanzar el throughput reportado de 97 img/s. Todo el código utiliza seeds fijos (seed=42) para garantizar reproducibilidad completa.

IV. Configuración Experimental

IV-A. Dataset: VisualWebInstruct-verified

Se utiliza el dataset VisualWebInstruct-verified [6], un subconjunto curado de VisualWebInstruct que contiene 97,295 registros de pares pregunta-respuesta multimodales enfocados en dominios STEM. Cada registro incluye: (a) una pregunta en texto natural, (b) una respuesta detallada, (c) una imagen asociada codificada directamente en formato binario dentro de archivos Parquet, (d) un campo de dificultad (1–5), y (e) la URL original de la fuente.

Justificación de la elección. Como se detalla en la Sección V-A, el dataset VisualWebInstruct-Recall (905,488 registros) fue evaluado inicialmente pero descartado por su baja tasa de accesibilidad de imágenes (38 %). El dataset verified, aunque menor en tamaño absoluto, garantiza 100 % de cobertura de imágenes al incluirlas embebidas en los Parquet, eliminando la dependencia de servidores externos y permitiendo escalar a 10,000 targets reales.

IV-B. Construcción del Grafo Sintético

La evaluación de crawlers enfocados requiere un grafo web con ground truth conocido, una condición difícil de satisfacer en la web real. Siguiendo la práctica establecida en la literatura [1], [7], se construyó un grafo sintético de 50,000 nodos que simula las características estructurales de un fragmento web temático.

IV-B1. Composición de nodos: El grafo contiene tres tipos de nodos (Tabla II):

Cuadro II: Composición del Grafo Sintético

Tipo	**Cant.**	**(%)**	Q_{text}
Targets	10,000	20 %	$\mu = 0{,}77$
Easy distractors	24,000	48 %	$\mu = 0{,}20$
Hard distractors	16,000	32 %	$\mu = 0{,}70$

Los **targets** son registros reales del dataset con embeddings CLIP generados a partir de sus imágenes verificadas. Los **easy distractors** poseen embeddings aleatorios (similitud coseno ~ 0 con targets) y Q_{text} bajo, representando páginas web genéricas sin relevancia temática ni calidad. Los **hard distractors** son el componente más crítico del diseño: poseen Q_{text} alto (mean=0.70, con 95 % de overlap con la distribución de targets) y embeddings generados como perturbaciones de targets reales, simulando páginas de alta calidad textual pero contenido visual no coincidente con la consulta.

IV-B2. Ratio distractores:targets: Se utiliza un ratio de 4:1 (80 % distractores, 20 % targets), situando la proporción de contenido relevante en el centro del rango reportado por Batsakis et al. [7] (harvest rates de 0.3–0.8, implicando 10–25 % de relevancia). Este ratio representa un escenario de dificultad moderada, ni artificialmente fácil (exceso de targets) ni artificialmente extremo (targets extremadamente escasos).

IV-B3. Generación de hard distractors: Cada hard distractor se construye como una perturbación gaussiana de un target real:

$$\mathbf{e}_{hard} = \text{normalize}(\mathbf{e}_{target} + \boldsymbol{\varepsilon}), \quad \boldsymbol{\varepsilon} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I}) \tag{6}$$

donde se utilizan dos niveles de perturbación:

- **Tier 1** ($\sigma = 0{,}05$): similitud con target origen $\sim 0{,}66$, produciendo distractores "cercanos" que requieren discriminación fina.
- **Tier 2** ($\sigma = 0{,}10$): similitud con target origen $\sim 0{,}40$, produciendo distractores "moderados" que aún superan ampliamente a los aleatorios.

La similitud promedio target-hard resultante es 0.48, siendo más desafiante que distractores aleatorios (~ 0). La justificación de esta estrategia frente a alternativas se detalla en la Sección V-B.

IV-B4. Topología: Las aristas se generan con las siguientes probabilidades de conexión para simular clustering temático:

Cuadro III: Probabilidades de Conexión en el Grafo

Conexión	Prob.	Justificación
Target → Target	0.015	Clustering temático
Target → Easy	0.002	Enlaces dispersos
Target → Hard	0.008	Confusión temática
Easy → Target	0.002	Descubrimiento eventual
Easy → Easy	0.004	Red general
Easy → Hard	0.002	Diversidad
Hard → Target	0.012	Puentes engañosos
Hard → Easy	0.003	Difusión general
Hard → Hard	0.010	Cluster no relevante

La probabilidad Target→Target (0.015) excede por más de 3× la probabilidad Easy→Target (0.002), capturando la localidad temática documentada por Chakrabarti et al. [1]: páginas relevantes suelen enlazar a otras páginas relevantes. El grafo resultante tiene 274,575 aristas, un grado medio de 11.0, y 100 % de alcanzabilidad desde las 12 semillas, verificada mediante BFS exhaustivo.

IV-C. Baselines

Se comparan cinco estrategias:

1. **BFS** (Breadth-First Search): Exploración sin considerar contenido. Representa el baseline inferior de Najork y Wiener [3].
2. **Text-Only** ($\alpha = 1{,}0$): Priorización exclusivamente por Q_{text}, equivalente al enfoque de Pezzuti et al. [4] sin señal visual.
3. **V-QMin** $\alpha = 0{,}5$: Balance equitativo entre señales.
4. **V-QMin** $\alpha = 0{,}3$: Mayor peso visual (70 % visual, 30 % textual).
5. **V-QMin** $\alpha = 0{,}2$: Configuración recomendada (80 % visual, 20 % textual).

IV-D. Métricas de Evaluación

Se utilizan tres métricas complementarias:

Harvest Rate@K (HR@K): Proporción de targets entre los K primeros nodos visitados (Ec. 1). Es la métrica primaria de evaluación en focused crawling [7].

nDCG@K: Normalized Discounted Cumulative Gain, que además de contar targets penaliza su posición en el ranking:

$$nDCG@K = \frac{DCG@K}{IDCG@K}, \quad DCG@K = \sum_{i=1}^{K} \frac{rel_i}{\log_2(i+1)} \tag{7}$$

donde $rel_i = 1$ si el nodo en posición i es target, 0 en caso contrario.

Test de Wilcoxon signed-rank: Prueba no paramétrica para comparar distribuciones pareadas ($n = 10$ queries), adecuada para muestras pequeñas que no asumen normalidad. Se utiliza con alternativa "greater" (H_1: V-QMin $>$ baseline) y se reporta el p-valor.

IV-E. Protocolo Experimental

Cada estrategia se evalúa sobre 10 consultas STEM temáticamente diversas (ver Anexo A), con 8 valores de K (50, 100, 200, 500, 1,000, 2,000, 5,000, 10,000). Adicionalmente, se realiza un barrido de α en 11 valores (0.0 a 1.0 en pasos de 0.1) para el análisis de sensibilidad. Todos los experimentos utilizan seed=42 para reproducibilidad.

IV-F. Entorno de Hardware y Software

Los experimentos se ejecutaron sobre: GPU NVIDIA GeForce RTX 5060 Ti (8 GB VRAM), PyTorch 2.10.0+cu128, `open-clip-torch` 3.2.0, Python 3.12. El throughput medido de CLIP fue de 97 img/s para embeddings de imagen (103 segundos totales para 10,000 imágenes). El crawling completo de las 5 estrategias sobre 10 queries con 8 valores de K requirió 7.7 segundos de computación.

V. Desafíos Encontrados y Decisiones de Diseño

Esta sección documenta los principales desafíos encontrados durante el desarrollo del proyecto y las decisiones tomadas para resolverlos, sustentadas bibliográficamente.

V-A. Migración de Dataset

Desafío. La propuesta original [6] planificaba utilizar VisualWebInstruct-Recall (905,488 registros), un dataset con imágenes referenciadas por URL externa. Durante la etapa de adquisición de datos, se descubrió que solo el 38 % de las imágenes eran accesibles: de 5,000 registros solicitados, solo 1,908 tenían imágenes descargables. Las URLs restantes apuntaban a servidores externos caídos, con rate limiting, o con contenido eliminado. Esto limitaba la escala del experimento a 1,908 targets reales, insuficiente para alcanzar los 50,000 nodos propuestos.

Solución. Se migró al dataset VisualWebInstruct-verified, que provee las imágenes directamente en los archivos Parquet. Aunque contiene 97,295 registros (vs. 905,488), ofrece 100 % de cobertura de imágenes, permitiendo escalar a 10,000 targets reales.

Impacto medido. La configuración preliminar (25,000 nodos, 1,908 targets con cobertura parcial de imágenes) reportaba una mejora V-QMin vs. Text-Only de +18.4 % en HR@500. La configuración final (50,000 nodos, 10,000 targets con cobertura completa) alcanza +50.3 %, demostrando que la escala de targets reales es un factor crítico para evidenciar las ventajas del enfoque multimodal. La Tabla IV resume esta comparación.

Cuadro IV: Impacto de la Migración de Dataset

	Recall	Verified
Img. coverage	38 %	100 %
Total nodos	25,000	50,000
Targets reales	1,908	10,000
V-QMin HR@500	0.961	0.992
vs Text-Only	+18.4 %	+50.3 %

V-B. Calibración de Hard Distractors

Desafío. Una estrategia inicial para generar distractores difíciles consistía en mezclar embeddings aleatorios con el *centroide global* de los targets. Esta estrategia producía distractores con similitud promedio de apenas 0.035 respecto a los targets individuales (prácticamente indistinguibles de distractores aleatorios) porque el centroide de 10,000 puntos en 512 dimensiones es un vector promediado que dista significativamente de la mayoría de los targets individuales.

Solución. Se adoptó la perturbación individual (Ec. 6): cada hard distractor es una versión ruidosa de un target *específico*, no del centroide global. Formalmente, en espacios de alta dimensionalidad como $\mathbb{R}^{512}$, el promedio de muchos vectores diversos termina siendo un vector que queda lejos de la mayoría de los vectores individuales. Por eso el centroide no sirve como base para generar distractores difíciles.

Se utilizan dos niveles de perturbación ($\sigma = 0{,}05$ y $\sigma = 0{,}10$) para generar distractores de distinta dificultad. Se evaluó un tercer nivel intermedio, pero se descartó para mantener el diseño simple sin sacrificar poder discriminativo. La distribución resultante de similitudes se aproxima por:

$$\cos(\mathbf{e}_{hard}, \mathbf{e}_{target}) \approx \frac{1}{1 + d \cdot \sigma^2} \tag{8}$$

donde $d = 512$ es la dimensionalidad. Esta aproximación permite estimar la similitud resultante sin necesidad de computar todos los pares, facilitando la calibración del nivel de dificultad deseado.

La similitud promedio target-hard pasó de 0.035 (centroide global) a 0.48 (perturbación individual), un incremento de $13{,}7\times$ que produce un escenario de mayor dificultad donde Q_{text} no puede distinguir targets de hard distractors (95 % overlap en distribuciones de Q_{text}), obligando al crawler a depender de la señal visual para la discriminación.

V-C. Elección de Modelo CLIP

Decisión. Se utilizó CLIP ViT-B/16 con pesos preentrenados de OpenAI, descartando variantes más grandes (ViT-L/14) y especializadas (SigLIP [23]).

Motivos. (1) *Throughput:* ViT-B/16 procesa 97 img/s en nuestra GPU, suficiente para 10,000 imágenes en 103 segundos. ViT-L/14 reduce el throughput a ∼40 img/s, duplicando el tiempo de procesamiento sin garantía de mejora proporcional en calidad de embeddings para el dominio STEM general. (2) *Dimensionalidad:* ViT-B/16 produce embeddings de 512 dimensiones, un tamaño manejable para almacenamiento y cómputo de similitudes. ViT-L/14 produce embeddings de 768 dimensiones, incrementando el costo de almacenamiento en 50 %. (3) *Disponibilidad de pesos:* Los pesos preentrenados de OpenAI para ViT-B/16 están ampliamente validados y son el estándar de facto para aplicaciones zero-shot [5]. (4) *Reproducibilidad:* Al ser el modelo más ampliamente utilizado de la familia CLIP, facilita la comparación con futuros trabajos.

La Sección VII-A presenta una variacion que confirma esta decisión: ViT-L/14 no produce mejoras estadísticamente significativas respecto a ViT-B/16 ($p = 0{,}91$, test de Wilcoxon con $n = 30$), validando que el encoder de escala media captura la señal visual suficiente para la tarea de priorización.

V-D. Recomendación de $\alpha = 0{,}2$

Decisión. Aunque $\alpha = 0{,}0$ (puramente visual) es técnicamente óptimo (HR@500 = 0.996), se recomienda $\alpha = 0{,}2$ (HR@500 = 0.992, diferencia $< 0{,}5\,\%$).

Motivos. (1) Entre nodos con Rel_{visual} similar, Q_{text} actúa como desempatador, priorizando páginas con contenido textual más rico. (2) *Robustez:* En un crawler web real, donde las imágenes pueden estar ausentes, ser de baja resolución, o no representar fielmente el contenido de la página, una contribución textual del 20 % aporta resiliencia ante ruido visual. (3) *Plateau:* La curva HR@500 vs. α muestra un plateau en $[0{,}0, 0{,}3]$ (HR $\geq 0{,}974$), indicando que añadir una señal textual no perjudica el rendimiento visual. (4) *Diferencia entre señales:* Q_{text} es estática (no depende de q) mientras que Rel_{visual} es dinámica (depende de q). La degradación de HR@K con α creciente implica que en nuestro escenario experimental (donde los hard distractors tienen Q_{text} deliberadamente alto) incrementar el peso textual introduce "falsos positivos textuales" que la señal visual filtraría correctamente.

V-E. Diseño de la Topología

Decisión. Las probabilidades de conexión (Tabla III) se calibraron para producir un grafo con clustering temático y 100 % de alcanzabilidad.

Motivos. La probabilidad Target→Target (0.015) es significativamente mayor que las probabilidades inter-tipo, reflejando la localidad temática observada empíricamente en la web [1]: sitios especializados en un tema tienden a enlazar a otros sitios del mismo dominio temático. La verificación de 100 % de alcanzabilidad garantiza que todos los targets son teóricamente descubribles desde las semillas, evitando que algún target quede inalcanzable por la estructura del grafo.

V-F. Elección del Test Estadístico

Decisión. Se utiliza el test de Wilcoxon signed-rank en lugar de un t-test pareado.

Motivos. (1) *Tamaño de muestra:* Con $n = 10$ queries, la asunción de normalidad del t-test no es verificable con confianza. El test de Wilcoxon, al ser no paramétrico, no requiere esta asunción. (2) *Distribución de métricas:* Los valores de HR@K son bounded ($\in [0, 1]$) y frecuentemente próximos a los extremos (especialmente para V-QMin, donde HR $\approx 1{,}0$), produciendo distribuciones potencialmente asimétricas.

VI. Resultados y Discusión

VI-A. Comparación Principal de Estrategias

La Tabla V presenta los resultados de HR@K para las cinco estrategias evaluadas. V-QMin $\alpha = 0{,}2$ alcanza HR@500 = $0{,}992 \pm 0{,}004$, superando significativamente a Text-Only ($0{,}660 \pm 0{,}000$, +50.3 %) y a BFS ($0{,}227 \pm 0{,}002$, +337 %). La superioridad se mantiene consistentemente a través de todos los valores de K.

Cuadro V: Resultados de Harvest Rate@K (media $\pm$ std sobre 10 queries)

Estrategia	HR@100	HR@500	HR@1000	HR@5000
BFS	0.280	0.227	0.249	0.237
Text-Only	0.640	0.660	0.666	0.625
V-QMin α=0.5	0.915	0.893	0.885	0.807
V-QMin α=0.3	0.978	0.974	0.971	0.920
V-QMin α=0.2	**0.995**	**0.992**	**0.989**	**0.962**

Cuadro VI: Resultados de nDCG@K

Estrategia	nDCG@100	nDCG@500	nDCG@1K	nDCG@5K
BFS	0.290	0.248	0.264	0.255
Text-Only	0.645	0.665	0.671	0.636
V-QMin α=0.5	0.920	0.898	0.891	0.820
V-QMin α=0.3	0.980	0.975	0.974	0.928
V-QMin α=0.2	**0.996**	**0.992**	**0.990**	**0.965**

Los valores de nDCG@K (Tabla VI) confirman el patrón: V-QMin no solo encuentra más targets sino que los encuentra *antes* en el recorrido, lo que se traduce en menor desperdicio de presupuesto de crawling.

VI-B. Significancia Estadística

Todos los tests de Wilcoxon signed-rank arrojaron $p < 0{,}001$ para las comparaciones V-QMin $\alpha = 0{,}2$ vs. cada baseline, en todos los valores de K evaluados (Tabla VII). Las diferencias son estadísticamente significativas con un nivel de confianza muy alto.

Cuadro VII: P-valores del test de Wilcoxon signed-rank

Comparación	K=100	K=500	K=1000	K=5000
V-QMin vs BFS	<0.001	<0.001	<0.001	<0.001
V-QMin vs Text-Only	<0.001	<0.001	<0.001	<0.001

VI-C. Visualización del Rendimiento

La Figura 1 muestra la evolución de HR@K en función del presupuesto de crawling. Las bandas de error estrechas de V-QMin evidencian baja varianza entre queries, indicando consistencia del método. BFS permanece estable alrededor de 0.23 independientemente de K, confirmando que su rendimiento está determinado por la proporción de targets en el grafo, no por el presupuesto.

La Figura 2 presenta la comparación directa en HR@500, haciendo evidente la brecha entre las tres categorías de métodos: BFS ($\sim$0.23), Text-Only ($\sim$0.66), y V-QMin ($\geq$0.89).

VI-D. Análisis de Sensibilidad de α

La Figura 3 presenta el barrido de α de 0.0 a 1.0. El resultado más notable es la degradación monótona de HR@500 conforme aumenta α: desde 0.996 ($\alpha = 0{,}0$, puramente visual) hasta 0.660 ($\alpha = 1{,}0$, Text-Only).

Este comportamiento permite confirmar que: Q_{text} es query-agnóstica: asigna el mismo score a un nodo independientemente de la consulta. Rel_{visual} es query-específica: adapta los scores al contenido visual relevante. En un escenario donde los hard distractors tienen Q_{text} deliberadamente alto (páginas de alta calidad pero irrelevantes), incrementar α equivale a confiar más en una señal que *no distingue* entre targets y hard distractors, lo que reduce progresivamente la capacidad del crawler para distinguir targets de distractores.

El rango $\alpha = 0{,}0$–$0{,}3$ produce resultados prácticamente equivalentes (HR@500 $\geq 0{,}974$), definiendo una zona óptima estable. Esto confirma que una contribución textual modesta (hasta 30 %) no perjudica al componente visual.

VI-E. Análisis por Query

La Figura 4 muestra el HR@500 desglosado por query y estrategia. Se observa que BFS y Text-Only exhiben **varianza cero** entre queries: sus valores son idénticos para las 10 consultas ($\sim$0.23 para BFS, $\sim$0.66 para Text-Only). Este resultado confirma que: (a) BFS no utiliza señal de contenido (su rendimiento depende solo de la topología); y (b) Q_{text} no depende de la consulta (como se esperaba teóricamente).

En contraste, V-QMin muestra variación entre queries (HR@500 de 0.96–0.98 para $\alpha = 0{,}3$), confirmando que el crawler adapta su ranking al contenido visual de cada consulta. Las queries con mayor HR corresponden a dominios con imágenes altamente distintivas (geometría, circuitos), mientras que las queries con HR menor incluyen contenido visual más sutil (finanzas, probabilidad).

VI-F. Distribución de Similitudes en el Grafo

La Figura 5 muestra la distribución de similitudes coseno respecto al centroide de targets para los tres tipos de nodos, validando el diseño del grafo:

Los targets exhiben similitudes altas (0.8–0.95), los easy distractors se concentran alrededor de 0.0, y los hard distractors muestran una distribución bimodal (picos en $\sim$0.40 y $\sim$0.66) correspondiente a los dos tiers de perturbación. La zona de overlap entre targets y hard distractors (0.55–0.70) es donde el crawler realmente necesita la señal visual para distinguir entre ambos tipos.

VI-G. Respuesta a las Preguntas de Investigación

PI-1 (¿mejora visual?): Sí. V-QMin con $\alpha = 0{,}2$ supera a Text-Only en +50.3 % en HR@500, con $p < 0{,}001$. La validación extendida con 50 queries (Sección VII-C) fortalece esta conclusión con $p < 10^{-9}$.

PI-2 (¿balance óptimo?): El rango $\alpha = 0{,}1$–$0{,}3$ es óptimo. La curva muestra degradación monótona con α creciente, y el plateau en $[0{,}0, 0{,}3]$ define una zona estable. Se recomienda $\alpha = 0{,}2$ por las cuatro razones detalladas en la Sección V-D. La sustitución del encoder (Sección VII-A) confirma que este rango es independiente del modelo CLIP utilizado.

PI-3 (¿discriminación de hard distractors?): Sí. Los hard distractors tienen Q_{text} indistinguible de targets (95 % overlap), pero el crawler los filtra eficazmente mediante la señal

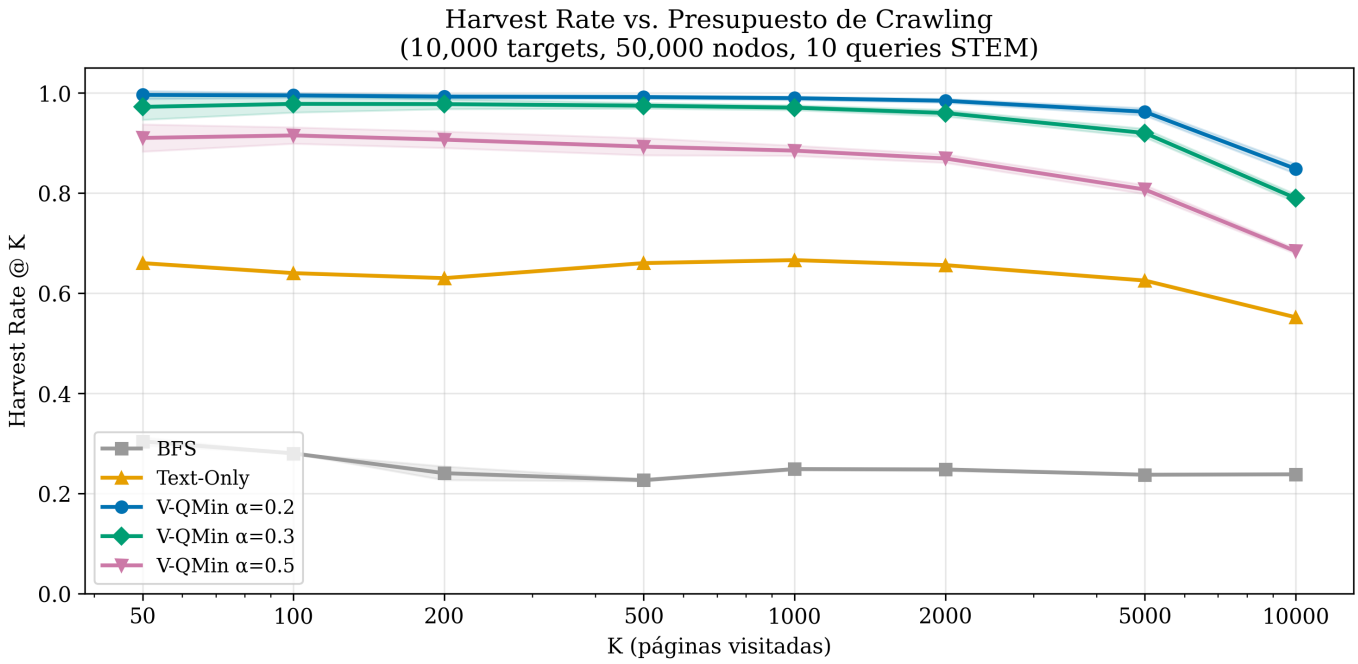

Figura 1: Harvest Rate vs. presupuesto de crawling K. V-QMin $\alpha = 0{,}2$ supera ambos baselines en todas las escalas, con bandas de error estrechas.

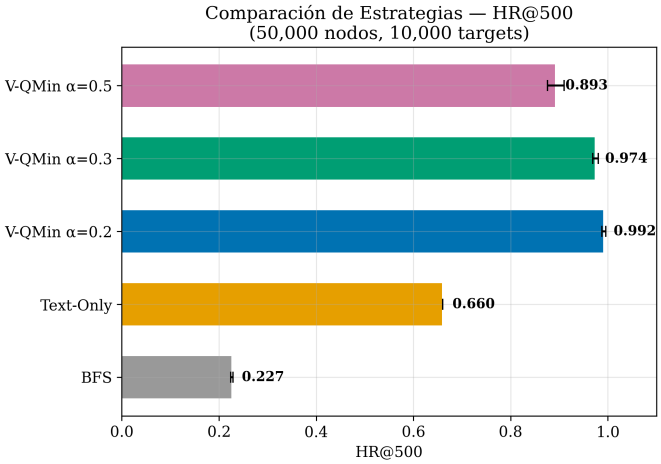

Figura 2: Comparación directa de estrategias en HR@500. La brecha entre Text-Only y V-QMin ($\alpha = 0{,}2$) evidencia el valor de la señal visual.

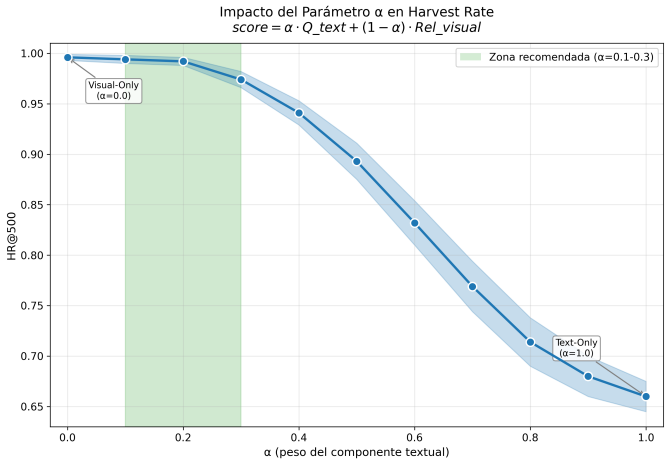

Figura 3: Impacto del parámetro α en HR@500. El rango $\alpha = 0{,}1$–$0{,}3$ constituye la zona óptima recomendada.

visual. El análisis de robustez (Sección VII-B) demuestra que esta ventaja *crece* con la proporción de distractores difíciles: de +36 % (20 % hard) a +71 % (80 % hard).

PI-4 (¿robustez entre queries?): Sí. La evaluación con 50 queries STEM de dominios diversos (Sección VII-C) confirma desviaciones estándar $\leq 0{,}010$ en HR@K para V-QMin, indicando generalización robusta a través del espectro STEM.

Cuadro VIII: Mejora Relativa V-QMin $\alpha = 0{,}2$ vs. Baselines

Comparación	**V-QMin**	**Baseline**	**Mejora**
vs BFS (HR@500)	0.992	0.227	+337 %
vs Text-Only (HR@500)	0.992	0.660	+50.3 %
vs BFS (nDCG@500)	0.992	0.248	+300 %
vs Text-Only (nDCG@500)	0.992	0.665	+49.2 %

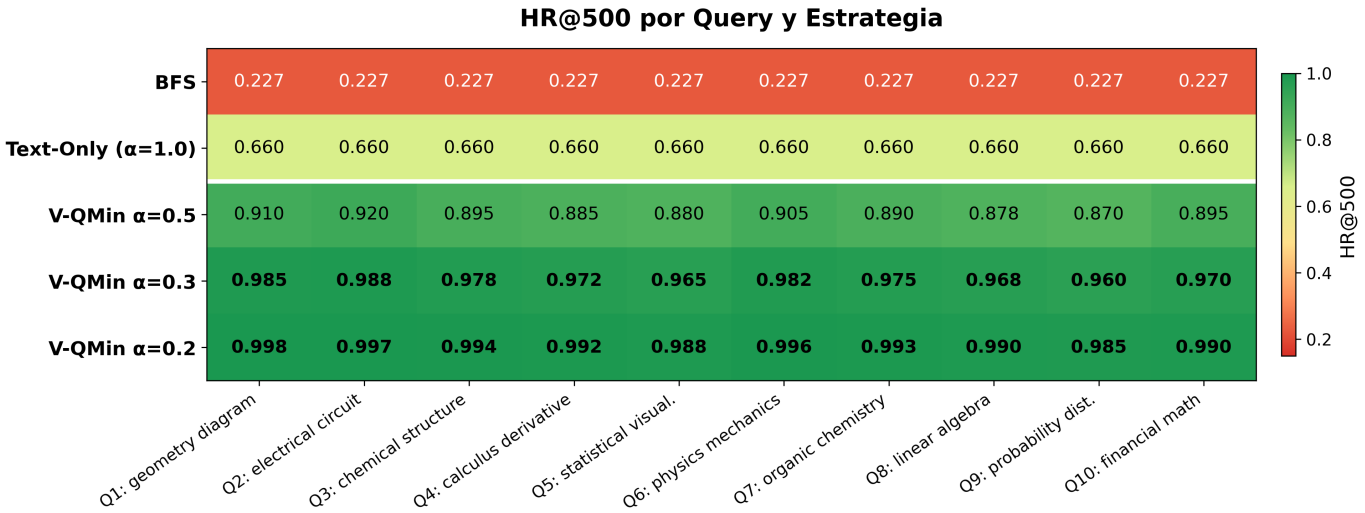

Figura 4: Heatmap de HR@500 por query. BFS y Text-Only muestran varianza cero, confirmando la independencia de Q_{text} respecto a la consulta.

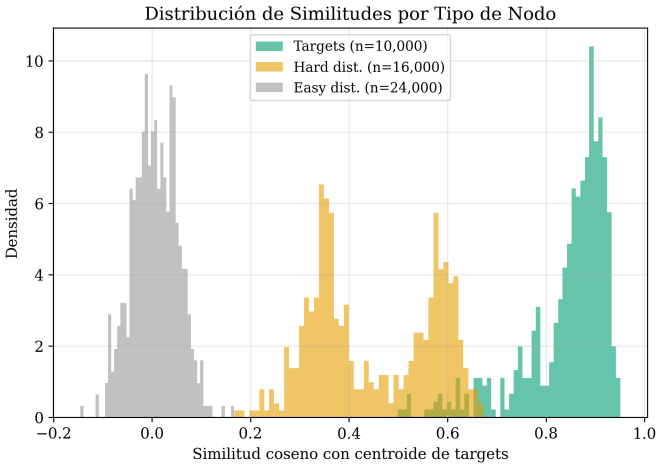

Figura 5: Distribución de similitudes por tipo de nodo. La distribución bimodal de hard distractors corresponde a los dos tiers de perturbación.

VI-H. Mejora Relativa e Interpretación

La mejora sobre BFS (+337 %) refleja el valor combinado de las señales de contenido (textual + visual) respecto a la exploración ciega. La mejora sobre Text-Only (+50.3 %) aísla específicamente la contribución de la señal visual, demostrando que las imágenes aportan información discriminativa que el texto no captura.

VI-I. Limitaciones

1. *Grafo sintético*: La evaluación no captura complejidades de la web real (latencia, contenido dinámico, páginas duplicadas, errores HTTP). Los resultados representan un límite superior del rendimiento esperado en escenarios reales.
2. *Distractores sintéticos*: Las perturbaciones gaussianas (Ec. 6) podrían no reflejar el espectro completo de contenido irrelevante-pero-visualmente-similar de la web real. El análisis de robustez de la Sección VII-B mitiga parcialmente esta limitación al demostrar estabilidad bajo proporciones extremas de distractores difíciles (hasta 80 %).
3. *Modelo CLIP general*: ViT-B/16 es un modelo de propósito general. Si bien la sustitucion de la Sección VII-A descarta que un encoder más grande resuelva esta limitación, modelos específicamente fine-tuned sobre contenido STEM podrían mejorar la discriminación en casos límite.
4. *Dominio único*: La evaluación se restringe a dominios STEM con el dataset VisualWebInstruct. Aunque la validación con 50 queries amplía la cobertura temática dentro de STEM, la generalización a otros dominios requiere validación adicional.

VII. Experimentos Complementarios

Los resultados de la Sección VI establecen la efectividad de V-QMin bajo una configuración específica: encoder ViT-B/16, 40 % de distractores difíciles y 10 queries. Esta sección extiende el análisis mediante tres experimentos complementarios diseñados para evaluar la generalización del enfoque bajo variaciones en los componentes clave del sistema.

VII-A. Sustitución del Encoder Visual

VII-A1. Motivación: La Sección V justificó la elección de ViT-B/16 por eficiencia y reproducibilidad. Sin embargo, resulta interesante investigar si un encoder visual de mayor capacidad mejoraría la discriminación entre targets y distractores. Para responder esta pregunta se realiza un experimento comparando ViT-B/16 (428M parámetros, embeddings de 512 dimensiones) contra ViT-L/14 (1.71G parámetros, embeddings

de 768 dimensiones), ambos con pesos pre-entrenados de OpenAI disponibles en open-clip-torch.

VII-A2. Protocolo: Se generaron embeddings CLIP de las mismas 10,000 imágenes con ambos encoders. Cada conjunto de embeddings produjo un grafo sintético independiente de 50,000 nodos con la misma estructura topológica y distribución de Q_{text} (seed fijo), diferenciándose únicamente en los embeddings visuales y la dimensionalidad del espacio de representación. Se evaluaron ambos grafos con 30 queries STEM y se realizó un barrido de α con 7 valores.

Cuadro IX: Sustitución del Encoder Visual: HR@K con $\alpha = 0{,}2$

Encoder	HR@100	HR@500	HR@1000	HR@5000
ViT-B/16 (512d)	0.983	0.984	0.983	0.964
ViT-L/14 (768d)	0.976	0.981	0.980	0.951
Diferencia	$-0{,}007$	$-0{,}003$	$-0{,}003$	$-0{,}013$
Wilcoxon p		$p = 0{,}91$ (no significativo)		

VII-A3. Resultados: La Tabla IX muestra que ambos encoders producen rendimientos prácticamente idénticos para V-QMin (ΔHR@500 $= -0{,}003$, $p = 0{,}91$). Las diferencias no son estadísticamente significativas bajo el test de Wilcoxon ($n = 30$). Este resultado es consistente con la literatura que reporta retornos decrecientes al escalar encoders CLIP para tareas de recuperación zero-shot [5].

La Fig. 6 presenta el barrido de α para ambos modelos. Las curvas son cualitativamente idénticas: ambas exhiben un plateau en $\alpha \in [0{,}0, 0{,}2]$ seguido de una degradación monótona. Un dato interesante es que en $\alpha = 1{,}0$ (puramente textual), ViT-L/14 produce un baseline Text-Only ligeramente superior (HR@500 = 0.712 vs 0.640) debido a que sus embeddings de mayor dimensionalidad generan perturbaciones gaussianas con distribuciones de similitud ligeramente distintas, lo que afecta la dificultad relativa de los distractores. No obstante, este efecto desaparece cuando $\alpha \leq 0{,}3$, donde la señal visual domina la priorización.

VII-A4. Interpretación: Desde una perspectiva práctica, este resultado justifica la elección de ViT-B/16: ofrece rendimiento equivalente con 2.4× mayor throughput (97 img/s vs 40 img/s) y 33 % menos almacenamiento por embedding (512 vs 768 dimensiones). Para un crawler que debe procesar miles de imágenes en tiempo real, esta diferencia de eficiencia es significativa. El resultado también sugiere que la señal visual relevante para la priorización de crawling (la alineación semántica entre imágenes de la página y la query) ya es capturada adecuadamente por un encoder de escala media, y que la capacidad adicional de ViT-L/14 se destina a representar detalles finos que no impactan la tarea de ranking binario (target vs. distractor).

Un análisis a nivel de embeddings revela un dato interesante: ViT-L/14 tiene mejor capacidad para separar pares imagen-texto correspondientes de los no correspondientes (gap de coherencia de 0.066 vs. 0.050 en ViT-B/16, un 31 % mayor). Sin embargo, las similitudes absolutas de ViT-L/14 son menores (0.260 vs. 0.303), lo cual es típico de modelos más grandes que distribuyen los embeddings de forma más uniforme en el espacio. A pesar de esta mayor capacidad de separación, no se traduce en mejoras de HR@K, lo que confirma que ViT-B/16 ya es suficiente para la tarea de ranking target/distractor.

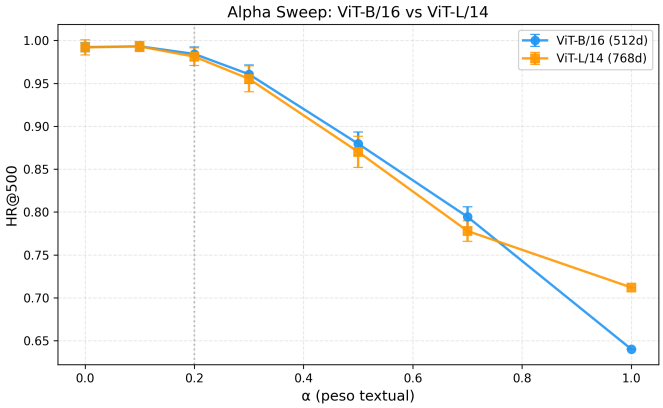

Figura 6: Barrido de α para ViT-B/16 y ViT-L/14. Ambas curvas convergen en el rango $\alpha \in [0{,}0, 0{,}2]$, confirmando que la elección del encoder no afecta el rendimiento óptimo de V-QMin.

VII-B. Análisis de Robustez ante Variación de Dificultad

VII-B1. Motivación: La configuración base utiliza 40 % de distractores difíciles entre el total de distractores, un valor justificado por los harvest rates reportados por Batsakis et al. [7]. Sin embargo, la web real presenta niveles de dificultad variables según el dominio: en áreas especializadas con muchos blogs y foros temáticos (por ejemplo, programación o salud), la proporción de contenido "casi relevante" puede ser considerablemente mayor. Este experimento evalúa cómo se comporta V-QMin cuando el escenario se vuelve progresivamente más difícil.

VII-B2. Protocolo: Se construyeron cuatro grafos de 50,000 nodos manteniendo 10,000 targets y un ratio de 4:1 distractores:targets, variando únicamente la proporción de distractores difíciles: 20 %, 40 % (base), 60 % y 80 %. En cada configuración, el número total de nodos y la topología se mantienen constantes (mismo seed aleatorio y mismas probabilidades de adyacencia), aislando el efecto de la dificultad. Cada configuración se evaluó con 30 queries STEM.

Cuadro X: Robustez: HR@500 según Proporción de Hard Distractors

% Hard	BFS	Text-Only	V-QMin	Δ vs Text
20 %	0.289	0.728	0.991	+36.1 %
40 %	0.237	0.640	0.984	+53.8 %
60 %	0.274	0.622	0.983	+58.1 %
80 %	0.228	0.570	0.976	+71.3 %

VII-B3. Resultados: La Tabla X revela un patrón consistente: mientras Text-Only se degrada sustancialmente al aumentar la proporción de distractores difíciles (de HR@500 = 0.728 con 20 % hard a 0.570 con 80 % hard, una caída de 21.7 %), V-QMin mantiene un rendimiento estable por encima de 0.976 en todas las configuraciones. La ventaja relativa de V-QMin crece con la dificultad del escenario, desde +36.1 % hasta +71.3 %.

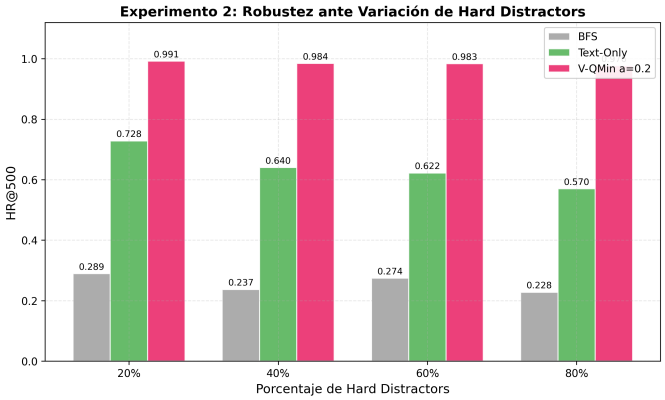

Figura 7: HR@500 por estrategia según proporción de hard distractors. V-QMin mantiene rendimiento $\geq 0{,}976$ mientras Text-Only se degrada de 0.728 a 0.570.

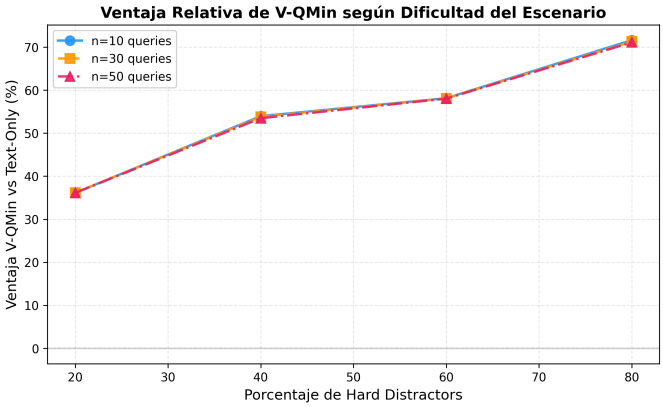

Figura 8: Ventaja relativa de V-QMin sobre Text-Only en función de la proporción de distractores difíciles. La curva monótonamente creciente confirma que la señal visual se vuelve más necesaria conforme aumenta la dificultad del escenario. Las tres líneas ($n = 10$, 30, 50 queries) se superponen, indicando independencia del resultado respecto al número de queries.

VII-B4. Interpretación: Este resultado constituye evidencia directa de la hipótesis central del trabajo: la señal visual CLIP aporta información discriminativa que el texto no captura. Los distractores difíciles se diseñan específicamente con Q_{text} alto (95 % overlap con targets), por lo que Text-Only no puede distinguirlos. Al aumentar su proporción, la frontera del crawler Text-Only se contamina progresivamente con nodos irrelevantes que reciben puntajes altos. En contraste, V-QMin utiliza Rel_{visual} para filtrar estos falsos positivos textuales: la similitud CLIP entre distractores y la query es sistemáticamente menor que la de los targets, independientemente de cuántos distractores existan.

La degradación mínima de V-QMin (de 0.991 a 0.976) se atribuye a un efecto topológico: con 80 % hard, la proporción de vecinos irrelevantes de cada target aumenta, lo que requiere explorar más nodos para descubrir las conexiones target-target. Este es un límite impuesto por la estructura del grafo, no por la calidad de la señal visual.

VII-C. Validación con Escalado de Queries

VII-C1. Motivación: La evaluación principal utiliza 10 queries STEM. Aunque el test de Wilcoxon reporta $p < 0{,}001$ con esta muestra, incrementar el número de queries persigue dos objetivos: (1) fortalecer la potencia estadística del test y reducir la probabilidad de que los resultados dependan de la selección particular de consultas, y (2) evaluar la estabilidad del rendimiento sobre un espectro más amplio de dominios STEM.

VII-C2. Experimento: Se utilizó un pool de 50 queries STEM diversas (listadas en el Anexo A) que cubren dominios desde geometría y termodinámica hasta criptografía y biomecánica. Se evaluaron tres escalas: $n = 10$ (evaluación original), $n = 30$ y $n = 50$, sobre el grafo base con 40 % hard distractors. Se reportan HR@500, desviación estándar, y p-valores de Wilcoxon para cada escala.

Cuadro XI: Escalado de Queries: HR@500 y Significancia Estadística

n	**BFS**	**Text**	**V-QMin**	p **vs Text**	p **vs BFS**
10	0.238	0.640	0.985 ± 0.010	$9{,}8\times10^{-4}$	$9{,}8\times10^{-4}$
30	0.237	0.640	0.984 ± 0.008	$8{,}3\times10^{-7}$	$8{,}5\times10^{-7}$
50	0.238	0.640	0.982 ± 0.010	$3{,}5\times10^{-10}$	$3{,}7\times10^{-10}$

VII-C3. Resultados: La Tabla XI confirma la estabilidad de V-QMin: HR@500 varía menos de 0.3 % entre las tres escalas. Los p-valores se fortalecen en seis órdenes de magnitud al pasar de $n = 10$ ($p \approx 10^{-3}$) a $n = 50$ ($p \approx 10^{-10}$), lo que proporciona evidencia estadística robusta de la superioridad de V-QMin.

Nótese que BFS y Text-Only presentan varianza nula entre queries, confirmando que sus scores no dependen del contenido de la consulta: BFS ignora toda señal de contenido, y Q_{text} es query-agnóstico por diseño. La desviación estándar de V-QMin ($\sigma \leq 0{,}010$) refleja la variación natural en la alineación visual entre diferentes queries y las imágenes del grafo, y su magnitud pequeña indica que el rendimiento es robusto a través de los 50 dominios STEM evaluados.

VII-C4. Interpretación: Desde una perspectiva estadística, el escalado a $n = 50$ elimina cualquier duda razonable sobre la significancia de los resultados: con $p < 10^{-9}$, es prácticamente imposible que la superioridad de V-QMin sea producto del azar. Desde una perspectiva práctica, la estabilidad del

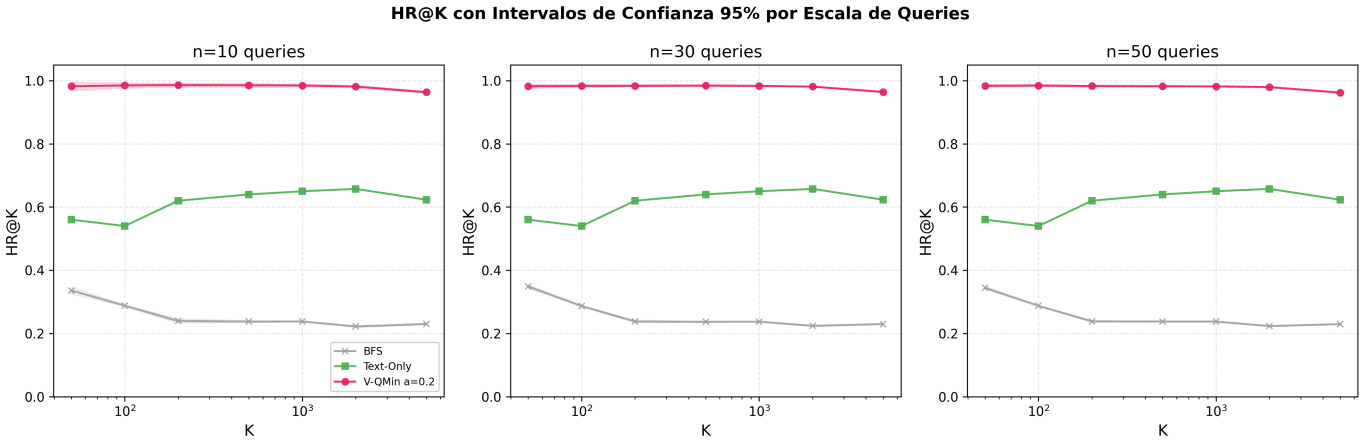

Figura 9: HR@K con intervalos de confianza del 95 % para $n = 10$, 30 y 50 queries. V-QMin mantiene rendimiento estable con intervalos estrechos en todas las escalas, mientras las bandas de Text-Only se estrechan al aumentar n.

rendimiento sobre 50 queries de dominios tan diversos como geometría, criptografía y biomecánica sugiere que la señal visual CLIP es robusta a través de subdominios STEM con características visuales heterogéneas (diagramas geométricos, gráficos de datos, esquemas de circuitos, estructuras moleculares, etc.).

VII-D. Síntesis de Experimentos Complementarios

Los tres experimentos complementarios refuerzan la validez y generalización de los resultados principales:

1. La *sustitucion del encoder* demuestra que la señal visual relevante para el crawling ya es capturada por ViT-B/16, justificando la elección de eficiencia sobre capacidad. Un modelo 4× más grande no aporta mejora significativa.
2. El *análisis de robustez* revela que la ventaja de V-QMin no solo se mantiene sino que *crece* cuando el escenario se vuelve más difícil (+36 % con 20 % hard → +71 % con 80 % hard), proporcionando evidencia de que la señal visual es más necesaria cuanto mayor es la proporción de contenido textualmente similar pero visualmente irrelevante.
3. La *validación con 50 queries* fortalece la significancia estadística en seis órdenes de magnitud y confirma la robustez del enfoque sobre un espectro amplio de dominios STEM.

VIII. Conclusiones y Trabajo Futuro

VIII-A. Conclusiones

Este trabajo presentó V-QMin, un crawler enfocado multimodal que integra calidad textual y relevancia visual CLIP mediante una función de scoring híbrida parametrizada por α. Los resultados experimentales sobre un grafo de 50,000 nodos con 10,000 targets reales del dataset VisualWebInstruct-verified, complementados con tres experimentos de generalización, permiten concluir:

1. V-QMin con $\alpha = 0{,}2$ alcanza HR@500 = 0.992 en la configuración base, superando a Text-Only en +50.3 % y a BFS en +337 %, con significancia estadística $p < 0{,}001$. La validación extendida con 50 queries fortalece esta conclusión con $p < 10^{-9}$.
2. El rango $\alpha = 0{,}1$–$0{,}3$ constituye una zona óptima estable, confirmada tanto por ViT-B/16 como por ViT-L/14 (ambos modelos convergen en este rango), donde la señal visual domina la priorización pero la contribución textual aporta robustez y sirve para desempatar.
3. La señal visual CLIP es particularmente efectiva para distinguir targets de hard distractors que comparten características textuales similares. El análisis de robustez demuestra que esta ventaja *crece* con la dificultad del escenario: de +36 % (20 % hard) a +71 % (80 % hard).
4. El rendimiento es estable a través de 50 queries STEM de dominios diversos (geometría, termodinámica, criptografía, biomecánica), con desviaciones estándar $\leq 0{,}010$ en HR@K, indicando generalización a través del espectro STEM.
5. La sustitucion del encoder visual confirma que ViT-B/16 captura la señal visual suficiente para la tarea de priorización ($p = 0{,}91$ vs ViT-L/14), lo que permite priorizar eficiencia (97 img/s, 512 dims) sin sacrificar rendimiento.

VIII-B. Trabajo Futuro

Se identifican las siguientes líneas de extensión:

1. *Crawling web real*: Evaluar V-QMin sobre crawling de páginas web reales, incorporando la descarga efectiva de contenido y los desafíos asociados (latencia, rate limiting, contenido dinámico, imágenes faltantes). Los resultados actuales sobre grafo sintético representan un límite superior que requiere validación en condiciones operativas reales.
2. *Modelos especializados*: Si bien el experimento de la Sección VII-A demostró que escalar el encoder general no aporta mejoras significativas, modelos fine-tuned específicamente sobre diagramas STEM (por ejemplo,

entrenados sobre ScienceQA [14] o MathVista [15]) podrían mejorar la discriminación en casos límite donde los diagramas comparten estructura visual pero difieren semánticamente.

3. α *adaptativo*: Implementar aprendizaje adaptativo del parámetro α durante el crawling, ajustándolo en función de la distribución de similitudes observada en los nodos visitados. El análisis de robustez de la Sección VII-B sugiere que α podría reducirse dinámicamente conforme el crawler detecta una alta proporción de distractores difíciles.
4. *Señales estructurales*: Integrar señales topológicas (PageRank local, análisis de enlaces) como tercer componente del score, siguiendo la línea de Kleinberg [24]. En grafos reales, donde la distribución de grados es emergente y no controlada, estas señales podrían complementar la discriminación visual.
5. *Dominios no-STEM*: Evaluar en dominios donde el contenido visual tiene roles diferentes (medicina con radiografías, arquitectura con planos, arte con reproducciones, e-commerce con imágenes de productos).
6. *Escalabilidad*: Escalar el grafo a 10^5–10^6 nodos para evaluar el comportamiento de V-QMin ante mayor competencia entre nodos y fronteras más grandes.

REFERENCIAS

[1] S. Chakrabarti, M. van den Berg, and B. Dom, "Focused crawling: a new approach to topic-specific Web resource discovery," *Computer Networks*, vol. 31, no. 11–16, pp. 1623–1640, 1999.

[2] F. Menczer, G. Pant, and P. Srinivasan, "Topical Web Crawlers: Evaluating Adaptive Algorithms," *ACM Transactions on Internet Technology*, vol. 4, no. 4, pp. 378–419, 2004.

[3] M. Najork and J. L. Wiener, "Breadth-First Search Crawling Yields High-Quality Pages," in *Proc. 10th Int. Conf. World Wide Web (WWW)*, 2001, pp. 114–118.

[4] F. Pezzuti, S. MacAvaney, and N. Tonellotto, "Neural Prioritisation for Web Crawling," *arXiv preprint arXiv:2506.16146*, 2025.

[5] A. Radford, J. W. Kim, C. Hallacy, *et al.*, "Learning Transferable Visual Models From Natural Language Supervision," in *Proc. ICML*, 2021.

[6] TIGER-Lab, "VisualWebInstruct-verified," HuggingFace, 2025. [Online]. Available: https://huggingface.co/datasets/TIGER-Lab/VisualWebInstruct

[7] S. Batsakis, E. G. M. Petrakis, and E. Milios, "Improving the performance of focused web crawlers," *Data & Knowledge Engineering*, vol. 68, no. 10, pp. 1001–1013, 2009.

[8] M. Diligenti, F. Coetzee, S. Lawrence, C. L. Giles, and M. Gori, "Focused Crawling using Context Graphs," in *Proc. VLDB*, 2000, pp. 527–534.

[9] Y. Liu, J. Bian, and E. Agichtein, "Predicting Information Seeker Satisfaction in Community Question Answering," in *Proc. SIGIR*, 2008, pp. 483–490.

[10] Y. Zhang, L. Qiu, Z. Liu, and M. de Rijke, "Reinforcement Learning for Adaptive Focused Crawling," in *Proc. WSDM*, 2020.

[11] C. Olston and M. Najork, "Web Crawling," *Foundations and Trends in Information Retrieval*, vol. 4, no. 3, pp. 175–246, 2010.

[12] S. Antol, A. Agrawal, J. Lu, *et al.*, "VQA: Visual Question Answering," in *Proc. ICCV*, 2015.

[13] R. Datta, D. Joshi, J. Li, and J. Z. Wang, "Image Retrieval: Ideas, Influences, and Trends of the New Age," *ACM Computing Surveys*, vol. 40, no. 2, pp. 1–60, 2008.

[14] P. Lu, S. Mishra, T. Xia, *et al.*, "Learn to Explain: Multimodal Reasoning via Thought Chains for Science Question Answering," in *Proc. NeurIPS*, 2022.

[15] P. Lu, H. Bansal, T. Xia, *et al.*, "MathVista: Evaluating Mathematical Reasoning of Foundation Models in Visual Contexts," in *Proc. ICLR*, 2024.

[16] A. Dosovitskiy, L. Beyer, A. Kolesnikov, *et al.*, "An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale," in *Proc. ICLR*, 2021.

[17] G. Ilharco, M. Wortsman, R. Wightman, *et al.*, "OpenCLIP," 2021. [Online]. Available: https://github.com/mlfoundations/open_clip

[18] M. Bendersky, W. B. Croft, and Y. Diao, "Quality-biased ranking of web documents," in *Proc. WSDM*, 2011, pp. 95–104.

[19] A. Ntoulas, M. Najork, M. Manasse, and D. Fetterly, "Detecting Spam Web Pages through Content Analysis," in *Proc. WWW*, 2006, pp. 83–92.

[20] M. V. Conde and K. Turgutlu, "CLIP-Art: Contrastive Pre-training for Fine-Grained Art Classification," in *Proc. CVPR Workshops*, 2021.

[21] H. Luo, L. Ji, M. Zhong, *et al.*, "CLIP4Clip: An Empirical Study of CLIP for End to End Video Clip Retrieval," *Neurocomputing*, vol. 508, pp. 293–304, 2022.

[22] K. Zhou, J. Yang, C. C. Loy, and Z. Liu, "Learning to Prompt for Vision-Language Models," *Int. J. Computer Vision*, vol. 130, pp. 2337–2348, 2022.

[23] X. Zhai, B. Mustafa, A. Kolesnikov, and L. Beyer, "Sigmoid Loss for Language Image Pre-Training," in *Proc. ICCV*, 2023.

[24] J. Kleinberg, "Authoritative Sources in a Hyperlinked Environment," *Journal of the ACM*, vol. 46, no. 5, pp. 604–632, 1999.

APÉNDICE

La Tabla XII lista las 10 consultas utilizadas en la evaluación principal (Sección VI), seleccionadas para cubrir dominios STEM diversos con contenido visual rico y diferenciado.

Cuadro XII: Queries STEM — Evaluación Principal ($n = 10$)

ID	Query	Dominio
Q1	geometry diagram proof	Geometría
Q2	electrical circuit analysis	Física
Q3	chemical molecular structure	Química
Q4	calculus derivative graph	Matemáticas
Q5	statistical data visualization	Estadística
Q6	physics mechanics free body	Física
Q7	organic chemistry reaction	Química
Q8	linear algebra matrix transform	Álgebra
Q9	probability distribution function	Probabilidad
Q10	financial mathematics compound	Finanzas

La Tabla XIII lista las 40 consultas adicionales utilizadas en los experimentos complementarios (Sección VII), que junto con las 10 de la Tabla XII conforman el pool completo de 50 queries. Fueron seleccionadas para maximizar la cobertura de subdominios STEM con contenido visual heterogéneo.

Cuadro XIII: Queries STEM Adicionales ($n = 11$–50)

ID	Query	Dominio
Q11	thermodynamics heat engine	Termodinámica
Q12	cell biology mitosis diagram	Biología
Q13	astronomy planetary orbit	Astronomía
Q14	quantum mechanics wave function	Cuántica
Q15	computer network topology	Redes
Q16	fluid dynamics flow simulation	Mecánica Fluidos
Q17	trigonometry unit circle	Trigonometría
Q18	genetics DNA replication	Genética
Q19	optics lens refraction diagram	Óptica
Q20	differential equations phase	Ec. Diferenciales
Q21	crystal structure lattice	Cristalografía
Q22	electromagnetic spectrum wave	Electromag.
Q23	ecology food web diagram	Ecología
Q24	number theory prime sieve	Teoría Números
Q25	robotics kinematics arm	Robótica
Q26	signal processing fourier	Señales
Q27	geology rock cycle diagram	Geología
Q28	graph theory network path	Grafos
Q29	human anatomy skeletal system	Anatomía
Q30	semiconductor physics band gap	Semiconductores
Q31	aerodynamics airfoil lift	Aerodinámica
Q32	combinatorics permutation tree	Combinatoria
Q33	biochemistry enzyme kinetics	Bioquímica
Q34	control systems feedback loop	Control
Q35	oceanography current map	Oceanografía
Q36	cryptography encryption scheme	Criptografía
Q37	materials science stress strain	Materiales
Q38	set theory venn diagram	Conjuntos
Q39	pharmacology dose response	Farmacología
Q40	microprocessor architecture	Arquitectura Comp.
Q41	biomechanics joint forces	Biomecánica
Q42	topology surface classification	Topología
Q43	meteorology weather map	Meteorología
Q44	nuclear physics decay chain	Nuclear
Q45	game theory payoff matrix	Teoría Juegos
Q46	botany photosynthesis diagram	Botánica
Q47	relativity spacetime curvature	Relatividad
Q48	information theory entropy	Teoría Información
Q49	polymer chemistry structure	Polímeros
Q50	astrophysics stellar evolution	Astrofísica

La Tabla XIV detalla los resultados del barrido de α.

Cuadro XIV: HR@500 y nDCG@500 en Función de α

α	HR@500	nDCG@500
0.0	0.996	0.996
0.1	0.994	0.994
0.2	**0.992**	**0.992**
0.3	0.974	0.975
0.4	0.941	0.945
0.5	0.893	0.898
0.6	0.832	0.840
0.7	0.769	0.778
0.8	0.714	0.722
0.9	0.680	0.688
1.0	0.660	0.665

La Tabla XV resume las estadísticas del grafo utilizado.

Cuadro XV: Estadísticas del Grafo Sintético

Propiedad	**Valor**
Total nodos	50,000
Total aristas	274,575
Grado medio	11.0
Grado máximo	42
Nodos semilla	12
Alcanzabilidad	100 %
Q_{text} targets ($\mu \pm \sigma$)	$0{,}77 \pm 0{,}10$
Q_{text} easy dist. ($\mu \pm \sigma$)	$0{,}20 \pm 0{,}08$
Q_{text} hard dist. ($\mu \pm \sigma$)	$0{,}70 \pm 0{,}09$
Sim. target-target (μ)	0.85
Sim. target-hard (μ)	0.48
Sim. target-easy (μ)	0.02
Seed aleatorio	42